

Clasificación de Péptidos Antimicrobianos mediante un Clasificador Bayesiano Semi-Ingenuo

Jazmín Alejandra Martínez Guerrero

martinez.ja@cicese.edu.mx

Centro de Investigación Científica y de Educación Superior de Ensenada (CICESE)

Ensenada, Baja California, México

ABSTRACT

Se propone un Clasificador Bayesiano Semi-Ingenuo (SNBC) para la identificación binaria de péptidos antimicrobianos (AMPs). Las secuencias son representadas mediante diez descriptores físico-químicos globales que capturan propiedades de longitud, carga, hidrofobicidad y estabilidad. Dado que las variables no siguen una distribución normal y presentan correlaciones estadísticamente significativas, se descartan el Gaussian Naive Bayes y el Clasificador Bayesiano Ingenuo estándar; en su lugar se discretizan los atributos y se aplica el procedimiento de mejora estructural basado en información mutua y condicional. El modelo aprende las tablas de probabilidad condicional mediante estimación de máxima verosimilitud con suavizado de Laplace. Una validación cruzada estratificada de diez *folds* sobre 6,612 instancias reporta una exactitud de 0.731, sensibilidad de 0.728, especificidad de 0.734, F1-score de 0.730 y MCC de 0.464.

Formato de referencia:

Jazmín Alejandra Martínez Guerrero. 2026. Clasificación de Péptidos Antimicrobianos mediante un Clasificador Bayesiano Semi-Ingenuo. In *Reconocimiento de Patrones*. CICESE, Ensenada, Baja California, México, 4 pages.

1 INTRODUCCIÓN

La resistencia bacteriana a los antibióticos convencionales constituye una de las amenazas más graves para la salud pública global. Los péptidos antimicrobianos (AMPs) representan una familia de moléculas de defensa innata con actividad de amplio espectro, capaces de actuar contra bacterias, hongos y virus con mecanismos que dificultan el desarrollo de resistencias. Sin embargo, la identificación experimental de AMPs es costosa y lenta. La predicción computacional a partir de la secuencia de aminoácidos permite priorizar candidatos para validación *in vitro*, reduciendo así el costo y el tiempo del proceso de descubrimiento.

En este trabajo se aplica el Clasificador Bayesiano Semi-Ingenuo (SNBC), un MGP que extiende el Naive Bayes mediante eliminación y combinación de atributos dependientes, para la clasificación binaria de péptidos como antimicrobianos o no antimicrobianos. El objetivo es modelar el problema (con la representación y aprendizaje de parámetros) para luego realizar inferencia y con ello tener una evaluación experimental del modelo.

2 DATOS

2.1 Fuentes de datos

El conjunto positivo comprende 3,306 AMPs naturales con actividad antimicrobiana conocida extraídos de la base de datos APD3 (*Antimicrobial Peptide Database*). El conjunto negativo se construyó a partir de 180,264 péptidos sin actividad antimicrobiana anotada de UniProtKB, filtrados para longitudes de 1–200 aminoácidos. Para garantizar la calidad de los datos, se retuvieron únicamente secuencias compuestas por los 20 aminoácidos canónicos, eliminando entradas con residuos desconocidos (símbolo X).

Dado que la distribución de longitudes del conjunto negativo original (mediana: 127 aa) difiere significativamente de la del positivo (mediana: 29 aa), un clasificador entrenado con ese desbalance podría aprender a discriminar por longitud en lugar de por actividad biológica. Para evitar este sesgo, se realizó un muestreo estratificado por longitud del conjunto negativo de manera que su distribución empírica de longitudes replicase exactamente la del positivo, obteniendo un conjunto balanceado de 3,306 instancias negativas. El conjunto final contiene 6,612 péptidos con distribución de clases 1:1.

2.2 Representación de características

Cada péptido se describe mediante diez descriptores físico-químicos globales calculados con la biblioteca modLAMP: longitud de secuencia (Length), peso molecular (MW), carga neta a pH 7 (Charge), densidad de carga (Charge Density), punto isoelectrico (pI), índice de inestabilidad (Instability), aromaticidad (Aromaticity), índice alifático (Aliphatic), índice de Boman (BomanInd) y razón de hidrofobicidad (HydrophRatio). Estos descriptores han demostrado ser informativos para distinguir AMPs de péptidos sin actividad antimicrobiana, capturando propiedades estructurales clave como la anfipathicidad, la carga positiva y la hidrofobicidad características de los AMPs (Cherkasov et al. (2009)).

3 MODELO

3.1 Justificación del modelo

El análisis exploratorio reveló dos condiciones que determinan la elección del modelo. Primero, el test de Kolmogorov-Smirnov rechazó la hipótesis de normalidad para todas las variables ($p < 0.001$ en todos los casos), descartando el Gaussian Naive Bayes. Segundo, la matriz de correlación mostró dependencias estadísticamente significativas entre atributos: la correlación entre Length y MW es de 0.99, entre BomanInd e HydrophRatio de 0.77, y entre Aliphatic e HydrophRatio de 0.77, entre otras. Estas dependencias violan

el supuesto de independencia condicional del Naive Bayes estándar. El SNBC aborda esta limitación de manera explícita mediante un procedimiento de mejora estructural, manteniendo al mismo tiempo la eficiencia computacional y la interpretabilidad del modelo bayesiano.

Figure 1: Correlación entre las características de los péptidos




Figure 2: Qq-Plot de las variables *length*, *mw*, *instability* y *aromaticity*




Figure 3: Qq-Plot de las variables *charge*, *charge density*, *aliphatic* y *bomanind*





Figure 4: Qq-Plot de las variables *pi* y *hydrophratio*



3.2 Formalización del modelo

3.2.1 Definición de Variables.

- **Variable de Clase (C):** Variable aleatoria discreta que representa la actividad biológica del péptido.
 - $C \in \{0, 1\}$
 - $C = 1$ indica que el péptido es antimicrobiano.
 - $C = 0$ indica que no es antimicrobiano.
- **Espacio de Atributos Original (A):** El conjunto de atributos predictores comprende exclusivamente las características fisicoquímicas calculadas:

$$\mathbf{A} = (A_1, \dots, A_{10}) \quad (1)$$

• **Espacio de Atributos Optimizado (A'):**

$$\mathbf{A}' = (A'_1, \dots, A'_n), \quad n \leq 10 \quad (2)$$

Este espacio se obtiene tras las dos fases de mejora estructural descritas a continuación.

3.2.2 Mejora Estructural. El Clasificador Bayesiano Semi-Ingenuo (SNBC) extiende el Clasificador Bayesiano Ingenuo (NBC) mediante la eliminación o combinación de atributos que violan el supuesto de independencia condicional. El procedimiento sigue el Algoritmo 4.1 del libro *Probabilistic Graphical Models* de Luis Enrique Sucar.

Fase 1 — Eliminación de nodos

- Se elimina la variable `length` por redundancia con `mw`: dado que el peso molecular es la suma de los pesos de los aminoácidos, ambas variables comparten prácticamente la misma información ($I(\text{length}; \text{mw}) \approx 0.99$ en escala de correlación). Conservar ambas viola el espíritu del NBC sin aportar información adicional.
- Para cada atributo A_j restante se calcula la Información Mutua con la clase:

$$I(A_j; C) = \sum_{a_j} \sum_c P(A_j = a_j, C = c) \log_2 \frac{P(A_j = a_j, C = c)}{P(A_j = a_j)P(C = c)}$$

Los atributos con $I(A_j; C) < \varepsilon$ se eliminan por ser poco informativos para la predicción de la clase.

Fase 2 — Combinación de nodos

- Para cada par de atributos restantes (A_j, A_k) se calcula la Información Mutua Condicional dada la clase:

$$I(A_j; A_k | C) = \sum_c P(C = c) \sum_{a_j} \sum_{a_k} P(A_j = a_j, A_k = a_k | C = c) \log_2 \lambda \quad (3)$$

donde

$$\lambda = \frac{P(A_j = a_j, A_k = a_k | C = c)}{P(A_j = a_j | C = c)P(A_k = a_k | C = c)}$$

- Si $I(A_j; A_k | C) > \omega$, los atributos no son condicionalmente independientes dada la clase. En ese caso se combinan en un nuevo atributo A_{jk} cuyo dominio es el producto cartesiano de los dominios de A_j y A_k .

Tras esta transformación, los atributos del conjunto optimizado $\mathbf{A}'$ satisfacen la propiedad de independencia condicional:

$$P(A'_1, A'_2, \dots, A'_n | C) = \prod_{j=1}^n P(A'_j | C)$$

3.2.3 Parámetros del Modelo (Θ). El aprendizaje consiste en estimar las probabilidades a partir del conjunto de entrenamiento discretizado mediante Máxima Verosimilitud.

- **Probabilidades a priori de la clase:**

$$P(C = c_i) \sim \frac{N_i}{N}$$

donde N_i es el número de instancias de la clase c_i y N el total de instancias en el conjunto de entrenamiento.

- **Probabilidades condicionales de los atributos:**

$$P(A'_j = v_k | C = c_i) \sim \frac{N_{jki}}{N_i}$$

donde N_{jki} es el número de instancias de la clase c_i en las que el atributo A'_j toma el valor v_k .

3.2.4 Regla de Decisión (Inferencia). Dado un vector de características $\mathbf{a}' = (a'_1, \dots, a'_n)$, el clasificador asigna la clase c^* que maximiza la probabilidad posterior. Dado que la evidencia marginal $P(\mathbf{a}')$ es constante respecto a la clase, la regla de decisión se reduce a:

$$c^* = \arg \max_{c_i \in \{0,1\}} \left[P(C = c_i) \prod_{j=1}^n P(A'_j = a'_j | C = c_i) \right]$$

En la implementación se trabaja en espacio logarítmico para evitar *underflow* numérico:

$$c^* = \arg \max_{c_i} \left[\log P(C = c_i) + \sum_{j=1}^n \log P(A'_j = a'_j | C = c_i) \right]$$

3.2.5 Suavizado de Laplace. Si algún intervalo discretizado no aparece en los datos de entrenamiento para cierta clase, su probabilidad estimada por máxima verosimilitud sería cero, colapsando el producto posterior a cero independientemente de los demás atributos. Para evitar este problema se aplica el suavizado de Laplace, que asigna una pseudocuenta de $\alpha = 1$ a cada valor posible:

$$P(A'_j = v_k | C = c_i) = \frac{N_{jki} + 1}{N_i + K_j}$$

donde:

- N_{jki} : número de instancias de la clase c_i en las que $A'_j = v_k$.
- N_i : número total de instancias de la clase c_i en el conjunto de entrenamiento.
- K_j : número total de valores posibles (*bins*) del atributo A'_j .

De este modo, cada valor tiene probabilidad estrictamente mayor que cero, garantizando que la inferencia pueda evaluar cualquier secuencia nueva en validación cruzada.

3.3 Mejora estructural

La mejora estructural sigue un esquema greedy de dos fases aplicado exclusivamente sobre el conjunto de entrenamiento de cada k -fold para evitar el *data leakage*.

Fase 1: Eliminación de atributos irrelevantes: Se elimina *Length* por redundancia con *MW* (correlación 0.99). Para los atributos restantes se calcula la información mutua $I(A_j; C)$. Todo atributo con $I(A_j; C) < \varepsilon = 0.01$ es eliminado por no aportar información discriminante sobre la clase.

Fase 2: Resolución de dependencias condicionales: Para cada par (A_j, A_k) se calcula la información mutua condicional $CMI(A_j, A_k | C)$. Si $CMI > \omega = 0.05$, los dos atributos no son condicionalmente independientes dado C , y se combinan en un nuevo atributo A_{jk} cuyo espacio de valores es el producto cartesiano de los valores de A_j y A_k . Este proceso se repite hasta que no existan más pares

dependientes.

3.4 Aprendizaje de parámetros

3.4 Aprendizaje de parámetros

Dado que los atributos son continuos y no siguen distribuciones gaussianas, se discretizan mediante cuantilización en cuartiles. Los bordes de cuantilización se aprenden exclusivamente sobre el conjunto de entrenamiento de k -fold y se aplican al conjunto de prueba usando *pd.cut* con bordes fijos, evitando así la fuga de información. La probabilidad a priori de cada clase se estima como $P(c_i) \approx (N_i + 1)/(N + K)$, donde $K = 2$ es el número de clases. Las probabilidades condicionales de los atributos discretizados se estiman con suavizado de Laplace: $P(A_j = v_k | c_i) \approx (N_{jki} + 1)/(N_i + B_j)$, donde B_j es el número de valores distintos del atributo A_j . El suavizado de Laplace garantiza que ninguna probabilidad sea cero, evitando la aniquilación del producto en la ecuación del clasificador al encontrar valores no observados en el entrenamiento.

4 EVALUACIÓN EXPERIMENTAL

4.1 Protocolo de validación

Se empleó k -fold cross-validation, con semilla aleatoria fija (seed = 666) para garantizar la reproducibilidad. La estratificación asegura que la proporción de AMPs y no-AMPs (1:1) se mantenga aproximadamente constante en cada k -fold. Dentro de cada k -fold, la discretización y la mejora estructural se aprenden sobre los 5,950 ejemplos de entrenamiento ($\approx 90\%$) y se aplican a los 662 ejemplos de prueba (*approx* 10 %), sin ningún acceso a los datos de prueba durante el aprendizaje. Las métricas se promedian sobre los diez folds.

5 RESULTADOS

El modelo alcanza una exactitud media de 73.1 % con desempeño equilibrado entre clases: sensibilidad de 72.8 % y especificidad de 73.4%. El F1-score de 0.730 confirma el balance entre precisión y cobertura. El MCC de 0.464 indica una correlación positiva moderada entre predicciones y etiquetas verdaderas, sustancialmente por encima del azar.

El entrenamiento en promedio tardó 0.0079 s y la inferencia 0.0177 s por k -fold, lo que pone de manifiesto la eficiencia computacional característica de los clasificadores bayesianos. Esta característica es especialmente relevante en escenarios de cribado virtual a gran escala, donde es necesario clasificar millones de péptidos candidatos.

6 DISCUSIÓN

La exactitud del 73.1% obtenida por el SNBC es competitiva para un modelo generativo de baja complejidad con solo nueve descriptores globales. La simetría entre sensibilidad (72.8 %) y especificidad (73.4 %) indica que el clasificador no favorece sistemáticamente ninguna de las dos clases, lo cual es deseable en el contexto de cribado donde tanto los falsos positivos (que incurrir en validación experimental innecesaria) como los falsos negativos (que omiten candidatos con actividad real) tienen costos significativos.

La mejora estructural demostró ser un paso indispensable: la presencia de correlaciones fuertes entre atributos como Length-MW (0.99) y BomanInd-HydrophRatio (0.77) habría generado estimaciones sesgadas de las probabilidades posteriores bajo el NBC estándar, ya que las variables correlacionadas cuentan su evidencia implícitamente más de una vez en el producto naive. Al combinar o eliminar estos atributos, el SNBC restaura en la práctica la propiedad de independencia condicional dentro del conjunto de atributos resultante.

La discretización mediante cuartiles introduce una pérdida de resolución inherente, lo que constituye la principal limitación del modelo. Alternativas como el Gaussian Naive Bayes con transformaciones de Box-Cox, o el uso de estimadores de densidad kernel, podrían capturar mejor la distribución real de los atributos y mejorar el rendimiento. Sin embargo, la distribución bimodal observada en varias variables sugiere que la suposición gaussiana tampoco sería completamente apropiada sin transformaciones adicionales, lo que justifica la elección de la discretización como solución pragmática.

En el contexto del modelado gráfico probabilista, el SNBC ilustra cómo la incorporación de conocimiento estructural (en este caso, la eliminación de redundancias y dependencias mediante información mutua) conduce a un modelo más fiel a la distribución real de los datos que el NBC canónico, sin incurrir en la complejidad de estructuras más generales como TAN o BAN. Esta propiedad hace del SNBC una opción adecuada cuando la interpretabilidad y la eficiencia computacional son prioritarias.

7 CONCLUSIONES

El trabajo demuestra que los MGP, incluso en sus formulaciones más simples, aportan ventajas concretas en problemas bioinformáticos: la representación probabilista explícita permite diagnosticar y corregir violaciones del supuesto de independencia, y las probabilidades posteriores resultantes son directamente interpretables como grados de confianza en la predicción. Como trabajo futuro se plantea comparar el SNBC con clasificadores TAN y BAN, explorar descriptores de composición local y validar el modelo sobre bases externas para estimar su capacidad de generalización.